

# Modèles Statistiques

## Partie 1 - Manipulation et décomposition matricielle

3<sup>ème</sup> année Ingénierie Informatique et Réseaux

Dr. HAJJAMI Riane

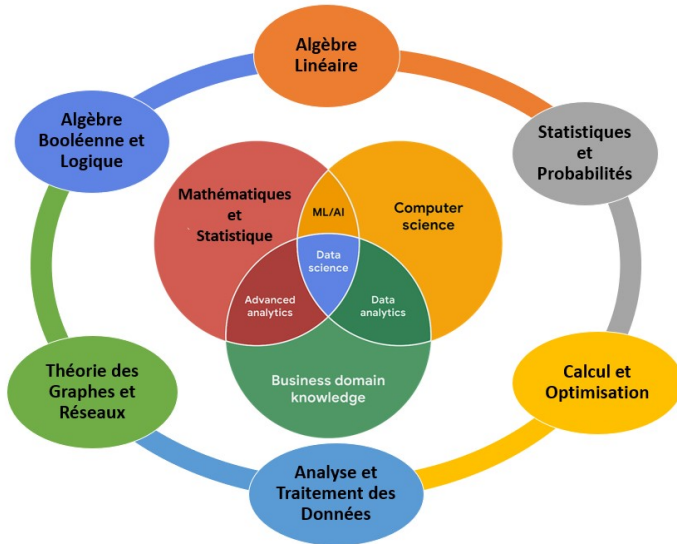
Semestre 2, Année universitaire 2024/2025



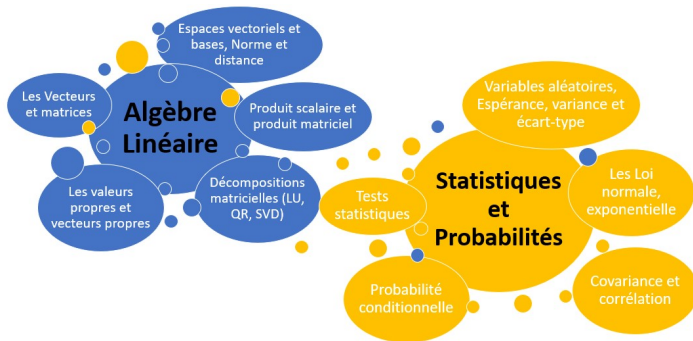
**ECOLE MAROCAINE DES  
SCIENCES DE L'INGENIEUR**

Membre de  
**HONORIS UNITED UNIVERSITIES**

# Introduction



# Introduction



# Plan de Cours

01

## Partie 1: Manipulation et décomposition matricielle

- Rappel des opérations de base sur les matrices
- Décomposition **LU**.
- Décomposition **QR**.
- Décomposition en valeurs singulières (**SVD**).

02

## Partie 2: Rappel des Statistique descriptive

- Types de données et échelles de mesure.
- Représentations **Graphiques**
- Mesures de tendance centrale : **moyenne**, **médiane**, **mode**.
- Mesures de dispersion : **variance** et **écart type** et **coefficient de variation**

03

## Partie 3: Espérance et probabilité conditionnelle

- Diagramme de **Venn**
- Théorème de **bayes** et **probabilité totale**
- Tableau de contingence
- Lois de distributions **discrètes** et **continues**

04

## Partie 4: Relations entre variables

- **Corrélation** : coefficient de corrélation de Pearson
- **Régression linéaire simple** : modèle et interprétation
- Modèle de **régression multiple**
- Modèle de **régression logistique binaire**

05

## Partie 5: Tests des hypothèses

- Tests des hypothèses (valeur P et intervalle de confiance)
- Test-T, test-Z
- Test chi-carrée
- Test ANOVA

# Partie 1 - Manipulation et décomposition matricielle

## 1 Rappel et Généralités

## 2 Décomposition matricielle

# Types des matrices

## Ligne ou colonne

$$[a_{11} \quad a_{12} \quad \cdots \quad a_{1n}]$$

Matrice Ligne

$$\begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{31} \end{bmatrix}$$

Matrice colonne

## Carrée

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

$\begin{matrix} \updownarrow \\ n \text{ ligne} \\ \updownarrow \end{matrix}$

$\begin{matrix} \leftarrow n \text{ colonne} \rightarrow \end{matrix}$

## Rectangulaire

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

$\begin{matrix} \updownarrow \\ n \text{ ligne} \\ \updownarrow \end{matrix}$

$\begin{matrix} \leftarrow m \text{ colonne} \rightarrow \end{matrix}$

$n \neq m$

## Nulle

$$\begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix}$$

## Identité

$$\begin{bmatrix} 1_{11} & \cdots & 0_{1n} \\ \vdots & \ddots & \vdots \\ 0_{n1} & \cdots & 1_{nn} \end{bmatrix}, \text{ Exemple : } \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

## Symétrique

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{12} & a_{22} & a_{23} \\ a_{13} & a_{23} & a_{33} \end{bmatrix}$$

$a_{ij} = a_{ji}$

## Diagonale

$$\begin{bmatrix} a_{11} & 0 & 0 \\ 0 & a_{22} & 0 \\ 0 & 0 & a_{33} \end{bmatrix}$$

## Triangulaire supérieur

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ 0 & a_{22} & a_{23} \\ 0 & 0 & a_{33} \end{bmatrix}$$

## Triangulaire inférieure

$$\begin{bmatrix} a_{11} & 0 & 0 \\ a_{21} & a_{22} & 0 \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

# Opérations sur les matrices

$A = (a_{ij})$  est une matrice de dimension  $m \times n$

$B = (b_{ij})$  est une matrice de dimension  $p \times q$

Pour tout  $1 \leq i \leq m$  et  $1 \leq j \leq n$  :


✧  $A = B \iff m = p; n = q$  et  $a_{ij} = b_{ij}$

✧  $C = A + B$  avec  $m = p$  et  $n = q$  :  $c_{ij} = a_{ij} + b_{ij}$

✧  $C = kA$  :  $c_{ij} = ka_{ij}$

✧  $C = A \times B$  :  $c_{ij} = \text{ligne } i|_A \times \text{colonne } j|_B$

✧  $A^n = \underbrace{A \times A \times \dots \times A}_{n \text{ fois}}$  si  $n \neq 0$  et  $A^0 = I$



$$(kA)B = k(AB)$$

$$ABC = (AB)C$$

$$= A(BC)$$

$$A(B + C) = AB + AC$$

$$(A + B)C = AC + BC$$

$$AI = IA = A$$

⚠ en général :

$$AB \neq BA$$

## Remarque

Le produit de deux matrices  $A \times B$  n'est possible que si le nombre de colonnes de  $A$  est égal au nombre de lignes de  $B$ .

# Inversion d'une matrice carrée

- Soit  $A \in \mathcal{M}_n(\mathbb{K})$  une matrice carrée de taille  $n$ . s'il existe  $A' \in \mathcal{M}_n(\mathbb{K})$  telle que

$$AA' = A'A = I_n.$$

Alors  $A$  est dite **inversible**.

- L'ensemble des matrices inversibles de taille  $n$  est noté  $GL_n(\mathbb{K})$ .
- Si  $\mathbf{A}^{-1}$  n'existe pas, la matrice  $\mathbf{A}$  est dite **singulière**



# Inversion d'une matrice carrée

## Propriétés

- $(\mathbf{A}^{-1})^{-1} = \mathbf{A}$
- $(\mathbf{A}^T)^{-1} = (\mathbf{A}^{-1})^T$
- $(\mathbf{AB})^{-1} = \mathbf{B}^{-1}\mathbf{A}^{-1}$  (Attention au changement d'ordre !)
- $[\text{diag}(\mathbf{D}_{ii})]^{-1} = \text{diag}(1/\mathbf{D}_{ii})$
- La matrice  $\mathbf{A}$  est dite **orthogonale** si  $\mathbf{A}^{-1} = \mathbf{A}^T$

# Méthodes de calcul de l'inverse d'une matrice carrée

## Méthode de Gauss-Jordan

### Opérations élémentaires

- **Dilatation** ou multiplication d'une ligne  $L_i$  par un scalaire  $\lambda$  non nul ( $\lambda \in \mathbb{K}^*$ ) ce que l'on note  $L_i \leftarrow \lambda L_i$ .
- **Permutations (ou plus exactement transpositions)** où on échange des lignes  $L_i$  et  $L_j$  avec  $i \neq j$  ce que l'on note  $L_i \leftrightarrow L_j$ ;
- **Transvections**: Ajout de  $\beta L_j$  à  $L_i$  avec  $i \neq j$  ce que l'on note  $L_i \leftarrow L_i + \beta L_j$  où  $\beta \in \mathbb{K}$ .

### Remarque

Les mêmes opérations élémentaires sont applicables sur les colonnes.

# Algorithme de Gauss-Jordan pour calcul de l'inverse d'une matrice

## 1 Augmenter la matrice :

$$\left[ \begin{array}{ccc|ccc} a_{11} & a_{12} & a_{13} & 1 & 0 & 0 \\ a_{21} & a_{22} & a_{23} & 0 & 1 & 0 \\ a_{31} & a_{32} & a_{33} & 0 & 0 & 1 \end{array} \right]$$

On forme la matrice augmentée  $[A|I]$  en combinant la matrice  $A$  et la matrice identité  $I$ .

## 2 Appliquer les opérations sur les lignes :

$$R_1 \rightarrow R_1 \cdot \frac{1}{a_{11}}, \quad R_2 \rightarrow R_2 - a_{21}R_1, \quad R_3 \rightarrow R_3 - a_{31}R_1$$

Ces opérations réduisent progressivement la matrice  $A$  à la matrice identité.

## 3 Obtenir l'inverse :

$$A^{-1} = \left[ \begin{array}{ccc} x_{11} & x_{12} & x_{13} \\ x_{21} & x_{22} & x_{23} \\ x_{31} & x_{32} & x_{33} \end{array} \right]$$

Lorsque le côté gauche devient l'identité, le côté droit devient  $A^{-1}$ .

# Exemple d'inversion par la méthode de Gauss-Jordan

On veut calculer l'inverse de la matrice suivante :

$$A = \begin{pmatrix} 2 & -4 & 4 \\ 2 & 0 & 1 \\ 4 & 1 & 1 \end{pmatrix}$$

La matrice augmentée associée est donc

$$\left( \begin{array}{ccc|ccc} 2 & -4 & 4 & 1 & 0 & 0 \\ 2 & 0 & 1 & 0 & 1 & 0 \\ 4 & 1 & 1 & 0 & 0 & 1 \end{array} \right)$$

# Exemple d'inversion par la méthode de Gauss-Jordan

- Le coefficient  $a_{1,1}$  est non nul on effectue donc  $L_2 \leftarrow L_2 - L_1$  et  $L_3 \leftarrow L_3 - 2L_1$ . On obtient,

$$\left( \begin{array}{ccc|ccc} 2 & -4 & 4 & 1 & 0 & 0 \\ 0 & 4 & -3 & -1 & 1 & 0 \\ 0 & 9 & -7 & -2 & 0 & 1 \end{array} \right)$$

- Le coefficient  $a_{2,2}$  est non nul on effectue donc  $L_2 \leftarrow \frac{1}{4}L_2$  pour simplifier la suite des calculs. On obtient,

$$\left( \begin{array}{ccc|ccc} 2 & -4 & 4 & 1 & 0 & 0 \\ 0 & 1 & -\frac{3}{4} & -\frac{1}{4} & \frac{1}{4} & 0 \\ 0 & 9 & -7 & -2 & 0 & 1 \end{array} \right)$$

## Exemple d'inversion par la méthode de Gauss-Jordan

$$\left( \begin{array}{ccc|ccc} 2 & -4 & 4 & 1 & 0 & 0 \\ 0 & 1 & -\frac{3}{4} & -\frac{1}{4} & \frac{1}{4} & 0 \\ 0 & 9 & -7 & -2 & 0 & 1 \end{array} \right)$$

- Le coefficient  $a_{2,2}$  vaut 1 on effectue donc  $L_3 \leftarrow L_3 - 9L_2$ . On obtient,

$$\left( \begin{array}{ccc|ccc} 2 & -4 & 4 & 1 & 0 & 0 \\ 0 & 1 & -\frac{3}{4} & -\frac{1}{4} & \frac{1}{4} & 0 \\ 0 & 0 & -7 + \frac{27}{4} & -2 + \frac{9}{4} & -\frac{9}{4} & 1 \end{array} \right)$$

- Le coefficient  $a_{3,3}$  est non nul. La matrice est donc inversible!

# Exemple d'inversion par la méthode de Gauss-Jordan

- Pour obtenir des 1 sur la diagonale, on effectue donc  $L_3 \leftarrow -4L_3$  et  $L_1 \leftarrow \frac{1}{2}L_1$ . On obtient,

$$\left( \begin{array}{ccc|ccc} 1 & -2 & 2 & \frac{1}{2} & 0 & 0 \\ 0 & 1 & -\frac{3}{4} & -\frac{1}{4} & \frac{1}{4} & 0 \\ 0 & 0 & 1 & -1 & 9 & -4 \end{array} \right)$$

- Le coefficient  $a_{3,3}$  est non nul on effectue donc  $L_2 \leftarrow L_2 + \frac{3}{4}L_3$  et  $L_1 \leftarrow L_1 - 2L_3$ . On obtient,

$$\left( \begin{array}{ccc|ccc} 1 & -2 & 0 & \frac{5}{2} & -18 & 8 \\ 0 & 1 & 0 & -1 & 7 & -3 \\ 0 & 0 & 1 & -1 & 9 & -4 \end{array} \right)$$

# Exemple d'inversion par la méthode de Gauss-Jordan

- Enfin, on fait  $L_1 \leftarrow L_1 + 2L_2$  et on obtient,

$$\left( \begin{array}{ccc|ccc} 1 & 0 & 0 & \frac{1}{2} & -4 & 2 \\ 0 & 1 & 0 & -1 & 7 & -3 \\ 0 & 0 & 1 & -1 & 9 & -4 \end{array} \right)$$

- Ceci produit l'identité à gauche et la matrice de droite est donc  $A^{-1}$ .  
ie :

$$A^{-1} = \begin{pmatrix} \frac{1}{2} & -4 & 2 \\ -1 & 7 & -3 \\ -1 & 9 & -4 \end{pmatrix}$$



# Méthodes de calcul de l'inverse d'une matrice carrée

## Méthode de déterminant

### Matrice $2 \times 2$

Soit  $A = \begin{pmatrix} a & b \\ c & d \end{pmatrix}$  une matrice carrée de taille  $2 \times 2$ . Si  $\det(A) = ad - bc \neq 0$  alors  $A$  est inversible et on a :

$$A^{-1} = \frac{1}{ad - bc} \begin{pmatrix} d & -b \\ -c & a \end{pmatrix}$$

# Méthodes de calcul de l'inverse d'une matrice carrée

## Méthode de déterminant

### Matrice $3 \times 3$

Soit  $A = \begin{pmatrix} a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \\ c_1 & c_2 & c_3 \end{pmatrix}$  une matrice de taille  $3 \times 3$ . Si  $A$  est inversible alors son inverse

est  $A^{-1} = \frac{1}{\det A} \text{'com} A$  avec :  $\det A = a_1 \begin{vmatrix} b_2 & b_3 \\ c_2 & c_3 \end{vmatrix} - b_1 \begin{vmatrix} a_2 & a_3 \\ c_2 & c_3 \end{vmatrix} + c_1 \begin{vmatrix} a_2 & a_3 \\ b_2 & b_3 \end{vmatrix}$

$$\text{Et } \text{'com} A = \begin{pmatrix} + \begin{vmatrix} b_2 & b_3 \\ c_2 & c_3 \end{vmatrix} & - \begin{vmatrix} b_1 & b_3 \\ c_1 & c_3 \end{vmatrix} & + \begin{vmatrix} b_1 & b_2 \\ c_1 & c_2 \end{vmatrix} \\ - \begin{vmatrix} a_2 & a_3 \\ c_2 & c_3 \end{vmatrix} & + \begin{vmatrix} a_1 & a_3 \\ c_1 & c_3 \end{vmatrix} & - \begin{vmatrix} a_1 & a_2 \\ c_1 & c_2 \end{vmatrix} \\ + \begin{vmatrix} a_2 & a_3 \\ b_2 & b_3 \end{vmatrix} & - \begin{vmatrix} a_1 & a_3 \\ b_1 & b_3 \end{vmatrix} & + \begin{vmatrix} a_1 & a_2 \\ b_1 & b_2 \end{vmatrix} \end{pmatrix}$$

### Règle de Sarrus

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{11} & a_{12} \\ a_{21} & a_{22} & a_{23} & a_{21} & a_{22} \\ a_{31} & a_{32} & a_{33} & a_{31} & a_{32} \end{pmatrix}$$

$$a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32}$$

$$\begin{pmatrix} a_{11} & a_{12} & a_{13} & a_{11} & a_{12} \\ a_{21} & a_{22} & a_{23} & a_{21} & a_{22} \\ a_{31} & a_{32} & a_{33} & a_{31} & a_{32} \end{pmatrix}$$

$$-a_{13}a_{22}a_{31} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33}$$

$$\det(A) = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} \\ - a_{13}a_{22}a_{31} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33}.$$

# Méthodes de calcul de l'inverse d'une matrice carrée

## Méthode de déterminant

Matrice  $n \times n$

$$\det(A) = \sum_{j=1}^n (-1)^{i+j} a_{ij} A_{ij}$$

Si  $\det(A) \neq 0$  alors  $A$  est inversible et on a :

$$A^{-1} = \frac{1}{\det(A)} {}^T \text{Com}(A),$$

Où  $\text{Com}(A) = ((-1)^{i+j} A_{ij})$ , avec  $A_{ij}$  est le déterminant de la sous-matrice obtenue en éliminant la ligne  $i$  et la colonne  $j$  de la matrice  $A$ .

# Exemple d'inversion par la méthode de déterminant

Calculons l'inverse de la matrice

$$A = \begin{pmatrix} 1 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 1 \end{pmatrix}$$

on a

$$\text{Com}(A) = \begin{pmatrix} + \begin{vmatrix} 0 & 0 \\ 1 & 1 \end{vmatrix} & - \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} & + \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} \\ - \begin{vmatrix} 0 & 1 \\ 1 & 1 \end{vmatrix} & + \begin{vmatrix} 1 & 1 \\ 0 & 1 \end{vmatrix} & - \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} \\ + \begin{vmatrix} 0 & 1 \\ 0 & 0 \end{vmatrix} & - \begin{vmatrix} 1 & 1 \\ 1 & 0 \end{vmatrix} & + \begin{vmatrix} 1 & 0 \\ 1 & 0 \end{vmatrix} \end{pmatrix}$$

# Exemple d'inversion par la méthode de déterminant

Donc

$$\text{com } A = \begin{pmatrix} 0 & -1 & 1 \\ 1 & 1 & -1 \\ 0 & 1 & 0 \end{pmatrix}$$

alors

$$(\text{com } A)^T = \begin{pmatrix} 0 & 1 & 0 \\ -1 & 1 & 1 \\ 1 & -1 & 0 \end{pmatrix}$$

D'autre part,  $\det(A) = 1$ . On conclut que

$$A^{-1} = \frac{1}{\det A} (\text{com } A)^T = \begin{pmatrix} 0 & 1 & 0 \\ -1 & 1 & 1 \\ 1 & -1 & 0 \end{pmatrix}$$

# Inversion par la méthode de déterminant

## Proposition

- le déterminant de la matrice nulle  $0_n$  vaut 0,
- le déterminant de la matrice identité  $I_n$  vaut 1,
- Le déterminant d'une matrice triangulaire supérieure (ou inférieure) est égal au produit des termes diagonaux.
- Le déterminant d'une matrice diagonale est égal au produit des termes diagonaux.
- $\det(AB) = \det A \cdot \det B$
- $\det(A^{-1}) = \frac{1}{\det A}$
- $\det(A^T) = \det A$ .

# Inversion d'une matrice carrée

## Remarque

Les méthodes précédentes permettent de calculer la solution en calculant l'inverse de la matrice associée s'il existe, c'est-à-dire si  $\det(A) \neq 0$ . En effet,

$$AX = B \Leftrightarrow X = BA^{-1},$$

avec  $A \in \mathcal{M}_n(\mathbf{R})$ ,  $b \in \mathbf{R}^n$  et  $X \in \mathbf{R}^n$ .

# Rang d'une matrice

## Définition

Soit  $\mathcal{A}$  une matrice à  $n$  lignes et  $p$  colonnes, de terme général  $a_{i,j}$  appartenant à  $\mathbf{K}$ . Les vecteurs colonnes de  $\mathcal{A}$  sont notées  $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_p$  sont des vecteurs de  $\mathbf{K}$ . On appelle rang de  $\mathcal{A}$  la dimension du sous-espace vectoriel de  $\mathbf{K}^n$  engendré par  $\mathcal{C}_1, \mathcal{C}_2, \dots, \mathcal{C}_p$ .



# Rang d'une matrice

- Si  $\mathcal{A}$  est une matrice à  $n$  lignes et  $p$  colonnes, son rang est inférieur ou égal au minimum de  $n$  et de  $p$ .
- Les opérations élémentaires conservent le rang de la matrice.
- La suppression d'une colonne nulle ou d'une ligne nulle préserve le rang.
- Le rang d'une matrice  $A \in M_{n,p}(\mathbb{K})$  est égal au nombre de lignes ou de colonnes de la plus grande sous-matrice carrée de déterminant non nul que l'on peut extraire de  $A$ .
- Pour une matrice carrée  $A$  de  $M_n(\mathbb{K})$ , on a :

$$A \text{ inversible} \iff \text{rang } A = n.$$

# Valeurs propres-vecteurs propres

Soit  $A \in M_n(\mathbb{K})$

- $\lambda$  est dite **valeur propre** de la matrice  $A$  s'il existe un vecteur non nul  $X \in \mathbb{K}^n$  tel que

$$AX = \lambda X$$

- Le vecteur  $X$  est alors appelé **vecteur propre** de  $A$  associé à la valeur propre  $\lambda$ .
- Le **polynôme caractéristique** de  $A$  est


$$\chi_A(X) = \det(A - XI_n)$$

et on a

$$\lambda \text{ valeur propre de } A \iff \chi_A(\lambda) = 0$$

# Diagonalisation d'une matrice

- On dit qu'une matrice  $A$  est diagonalisable si elle est semblable à une matrice diagonale,  $D = P^{-1}AP$ . Diagonaliser  $A$ , c'est trouver  $D$  et  $P$ .



- s'il existe une matrice  $P$  inversible et une matrice  $D$  diagonale telle que  $A = PDP^{-1}$ , alors **pour tout**  $n \in \mathbf{N}$ ,  $A^n = PD^nP^{-1}$ .

# Partie 1 - Manipulation et décomposition matricielle

## 1 Rappel et Généralités

## 2 Décomposition matricielle

# Introduction à la Décomposition Matricielle

## Pourquoi décomposer une matrice ?

- En mathématiques et en **informatique**, la décomposition matricielle permet de réécrire une matrice sous une forme plus simple pour faciliter les calculs.
- Elle est essentielle pour résoudre des systèmes d'équations, analyser des données et optimiser des algorithmes.

### Applications en Informatique



#### Machine Learning et Intelligence Artificielle

- **Réduction de dimension** (PCA avec SVD) pour accélérer l'apprentissage automatique.
- **Optimisation des modèles** pour résoudre des systèmes d'équations linéaires.



#### Traitement d'Images et Vision par Ordinateur

- **Compression d'image** (JPEG) via SVD.
- **Filtrage et restauration** d'images avec QR.



#### Cybersécurité et Réseaux

- **Détection d'anomalies** dans les logs réseau via SVD.
- **Optimisation des protocoles de routage** grâce aux propriétés des matrices orthogonales (QR).



...

# Introduction à la Décomposition Matricielle

Les trois principales décompositions qui seront abordées dans ce cours:

## Décomposition LU (Lower-Upper)

- Factorise une matrice  $A$  en un produit de **deux matrices triangulaires** :  $A = LU$
- ↳ La résolution rapide de systèmes linéaires et les simulations numériques.

## Décomposition QR

- Exprime  $A$  sous la forme d'un **produit d'une matrice orthogonale et d'une matrice triangulaire** :  $A = QR$
- ↳ La régression linéaire et la stabilité numérique des calculs.

## Décomposition SVD (Singular Value Decomposition)

- Transforme une matrice en **trois matrices** avec des propriétés fondamentales :  $A = U\Sigma V^T$
- ↳ La compression de données, le traitement d'images et le ML.

# Décomposition LU

La décomposition  $LU$  consiste à écrire une matrice carrée  $A$  comme le produit de deux matrices: **une matrice triangulaire inférieure  $L$**  et **une matrice triangulaire supérieure  $U$**

$$\begin{array}{ccccc}
 \mathbf{A} & = & \mathbf{L} & \cdot & \mathbf{U} \\
 \begin{array}{ccccc}
 A_{11} & A_{12} & A_{13} & \cdots & A_{1n} \\
 A_{21} & A_{22} & A_{23} & \cdots & A_{2n} \\
 A_{31} & A_{32} & A_{33} & \cdots & A_{3n} \\
 \vdots & \vdots & \vdots & \ddots & \vdots \\
 A_{n1} & A_{n2} & A_{n3} & \cdots & A_{nn}
 \end{array} & = & \begin{array}{ccccc}
 1 & 0 & 0 & \cdots & 0 \\
 l_{21} & 1 & 0 & \cdots & 0 \\
 l_{31} & l_{32} & 1 & \cdots & 0 \\
 \vdots & \vdots & \vdots & \ddots & \vdots \\
 l_{n1} & l_{n2} & l_{n3} & \cdots & 1
 \end{array} & \cdot & \begin{array}{ccccc}
 U_{11} & U_{12} & U_{13} & \cdots & U_{1n} \\
 0 & U_{22} & U_{23} & \cdots & U_{2n} \\
 0 & 0 & U_{33} & \cdots & U_{3n} \\
 \vdots & \vdots & \vdots & \ddots & \vdots \\
 0 & 0 & 0 & 0 & U_{nn}
 \end{array} \\
 & & \underbrace{\hspace{10em}}_{\text{Triangulaire inférieure}} & & \underbrace{\hspace{10em}}_{\text{Triangulaire supérieure}}
 \end{array}$$

$$l_{ii} = 1, i = 1, 2, \dots, n$$

# Condition pour l'existence de la décomposition LU (cas d'une matrice carrée)

## Propriétés

Une matrice inversible  $A$  admet une décomposition  $LU$  si et seulement si tous ses mineurs principaux sont non nuls, où un mineur principal d'ordre  $k$  est le déterminant de la sous-matrice obtenue en gardant les  $k$  premières lignes et les  $k$  premières colonnes de  $A$ . Si l'on impose les valeurs, non nulles, de la diagonale de  $L$  (ou de  $U$ ), cette décomposition est unique.



# Condition pour l'existence de la décomposition LU (cas d'une matrice carrée)

## Propriétés

Une matrice inversible  $A$  admet une décomposition  $LU$  si et seulement si tous ses mineurs principaux sont non nuls, où un mineur principal d'ordre  $k$  est le déterminant de la sous-matrice obtenue en gardant les  $k$  premières lignes et les  $k$  premières colonnes de  $A$ . Si l'on impose les valeurs, non nulles, de la diagonale de  $L$  (ou de  $U$ ), cette décomposition est unique.

## Remarques

- Si cette condition n'est pas remplie, la décomposition LU existe tout de même, mais elle nécessite un pivotage, ce qui implique une réorganisation des lignes (ou des colonnes) de la matrice  $A$ .
- Dans ce cours, on se limite à la **décomposition LU de Crout qui impose que les éléments diagonaux de la matrice  $L$  sont fixés à 1.**

# Algorithme de décomposition LU

L'algorithme pour obtenir les matrices  $L$  et  $U$  est basé essentiellement sur des opérations élémentaires sur les lignes.

- **1.Initialisation** : on commence par poser  $L$  comme la matrice identité de taille  $n$  et  $U$  comme une copie de la matrice  $A$ .
- **2.Élimination de Gauss** pour chaque colonne  $j$  de la matrice  $U$ , à partir de la première jusqu'à la  $n$ -ième, soustrais de la  $i$ -ième ligne un multiple de la  $j$ -ième ligne pour annuler les éléments en dessous de la diagonale dans la colonne  $j$ . Le facteur multiplicatif utilisé pour cette opération sera stocké dans  $L_{ij}$ . La matrice  $U$  est modifiée à chaque étape de sorte qu'à la fin du processus, elle devient une matrice triangulaire supérieure.
- **3. Finalisation** A la fin de ces opérations sur toutes les colonnes, on obtient  $L$  comme une matrice triangulaire inférieure et  $U$  comme une matrice triangulaire supérieure telles que  $A = LU$ .

# Décomposition $LU$

## Exemple

# Décomposition $LU$

Application à la résolution d'un système d'équations linéaires

La résolution d'un système linéaire  $AX = B$  pour tout vecteur  $B$  devient plus simple si la matrice  $A$  peut être factorisée sous la forme  $LU$ ,

$$AX = B$$

 $\Rightarrow$ 

$$LUX = B$$

$$\Rightarrow \begin{cases} LY = B \\ UX = Y \end{cases}$$

$$\Rightarrow \left\{ \begin{array}{l} \text{Résolution par substitution avant (forward substitution)} \\ \begin{bmatrix} 1 & 0 & 0 & \cdots & 0 \\ l_{21} & 1 & 0 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ l_{n1} & l_{n2} & \cdots & l_{nn} & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix} \\ \text{Résolution par substitution arrière (backward substitution)} \\ \begin{bmatrix} u_{11} & u_{12} & \cdots & u_{1n} \\ 0 & u_{22} & \cdots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & u_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} \end{array} \right.$$

# Décomposition $LU$

## Cas d'une matrice rectangulaire


### Remarque

- La décomposition  $LU$  se généralise aux matrices rectangulaires  $A$  de taille  $m \times n$  avec  $m \geq n$ , en écrivant toujours  $A = LU$ , mais avec des structures adaptées : la matrice  $L$  devient une matrice de taille  $m \times n$  avec une structure triangulaire inférieure généralisée, tandis que  $U$  reste une matrice triangulaire supérieure carrée de taille  $n \times n$ .
- L'algorithme de calcul des éléments de  $L$  et  $U$  s'applique tel qu'il est à une matrice rectangulaire.
- La décomposition  $LU$  existe si la sous-matrice carrée  $n \times n$  formée par ces colonnes est inversible.

# Décomposition $PLU$

La décomposition  $LU$  n'est pas toujours possible, car un pivot nul peut apparaître, empêchant l'élimination sans permutation. La décomposition  $PLU$  résout ce problème en introduisant une matrice de permutation  $P$ , garantissant toujours une factorisation sous la forme :

$$PA = LU$$



# Décomposition LU

## Matrice de permutation

### Matrice de permutation

- Une matrice de permutation d'ordre  $n$  est une matrice carrée de taille  $n$  dont tous les coefficients sont égaux à 0, sauf un coefficient sur chaque ligne et sur chaque colonne égal à 1.
- Les matrices de permutation  $P_\sigma$  permettent de permuter les lignes et les colonnes d'une matrice  $A$ . Ainsi,  $AP_\sigma$  est la matrice déduite de  $A$  en permutant les colonnes de  $A$  suivant la permutation  $\sigma$ , et  $P_\sigma A$  est la matrice déduite de  $A$  en permutant les lignes de  $A$  suivant la permutation  $\sigma^{-1}$ ;

# Décomposition $PLU$

## Algorithme de décomposition $PLU$

L'algorithme repose sur l'élimination de Gauss avec pivotage partiel.

---

**Algorithme** Décomposition  $PLU$  avec pivotage partiel
 

---

**Entrée :** Matrice  $A$  de taille  $m \times n$

**Sortie :** Matrices  $P, L, U$  telles que  $PA = LU$

**Initialisation:**

Définir  $P$  comme la matrice identité de taille  $m$ .

Définir  $L$  comme la matrice identité de taille  $m$ .

Copier  $A$  dans  $U$ .

**Pivotage et Élimination de Gauss:**

**for**  $k = 1$  à  $\min(m, n)$  **do**

Rechercher l'indice  $p$  correspondant au plus grand élément en valeur absolue dans la colonne  $k$ , en considérant uniquement les lignes  $i \geq k$ .

**if**  $p \neq k$  **then**

Permuter les lignes  $k$  et  $p$  dans  $U$ .

Répercuter la permutation sur les lignes de  $P$ .

Répercuter également cette permutation sur les  $k - 1$  premières colonnes de  $L$ .

**end if**

**for**  $i = k + 1$  à  $m$  **do**

**if**  $U_{k,k} \neq 0$  **then**

Calculer le facteur d'élimination :

$$L_{i,k} = \frac{U_{i,k}}{U_{k,k}}$$

Insérer  $L_{i,k}$  dans  $L$  sous la diagonale.

Modifier les éléments de  $U$  en soustrayant la contribution de la ligne

$k$  :

$$U_{i,j} = U_{i,j} - L_{i,k} \cdot U_{k,j}, \quad \forall j \geq k$$

**end if**

**end for**

**end for**

**Retourner**  $P, L, U$ .

---



# Décomposition PLU

## Exemple

# Décomposition QR

Si  $A$  est **une matrice carrée** (réelle) de taille  $n$  inversible, alors il existe une **unique matrice orthogonale**  $Q$  et une **unique matrice triangulaire supérieure** à coefficients diagonaux strictement positifs  $R$  telle que

$$A = Q \cdot R$$

Matrice Orthonormal

Orthogonal  
 $Q \cdot Q^T = Q^T \cdot Q = I$


Colonnes unitaires

Triangulaire supérieur

Cette factorisation s'appelle **la décomposition QR** de la matrice  $A$ .

# Décomposition QR

Si la matrice  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  est **rectangulaire de rang  $n$  ou n'est pas inversible**, elle peut toujours se décomposer sous la forme  $A = QR$ , mais cette fois on ne peut plus demander que les coefficients diagonaux de  $R$  soient strictement positifs ni que la décomposition soit unique.



# Décomposition QR

Matrice orthogonale- Base orthogonale

Il existe plusieurs méthodes pour calculer la matrice orthogonale dans la décomposition QR. Dans ce cours, nous nous limiterons à **la méthode de Gram-Schmidt**. Introduisons d'abord quelques propriétés des matrices orthogonales et des bases orthogonales.

# Décomposition QR

Matrice orthogonale- Base orthogonale

Il existe plusieurs méthodes pour calculer la matrice orthogonale dans la décomposition QR. Dans ce cours, nous nous limiterons à **la méthode de Gram-Schmidt**. Introduisons d'abord quelques propriétés des matrices orthogonales et des bases orthogonales.

## Matrice orthogonale

- On dit qu'une matrice  $Q$  est orthogonale si  $Q^T Q = QQ^T = I$
- Le déterminant d'une matrice orthogonale est égal à 1 ou -1 .
- **Une matrice  $Q \in \mathcal{M}_{m,n}$  est orthogonale si et seulement si ses colonnes  $e_{i,i=1,\dots,n}$  (ou lignes) (vues comme des vecteurs) sont unitaires ( $\|e_i\| = 1$ ) et deux à deux orthogonales ( $\langle e_i, e_j \rangle = e_i^T e_j = 0, i \neq j$ ).**

# Décomposition QR

Matrice orthogonale- Base orthogonale

## Base orthogonale

- Un ensemble de vecteurs non nuls et mutuellement orthogonaux est toujours linéairement indépendant.
- Une famille orthogonale de vecteurs non nuls est une base de l'espace qu'elle engendre.
- Donnée une base de  $\mathbb{R}^n$ , il existe un procédé simple pour en déduire une base orthonormale. Essentiellement, on procède par projections successives d'un vecteur sur le sous-espace engendré par ses prédécesseurs. Il s'agit de procédé d'orthogonalisation de Gram-Schmidt.

# Décomposition QR

## Procédé d'orthonormalisation de Gram-Schmidt

Le procédé d'orthonormalisation de Gram-Schmidt permet de transformer une base quelconque d'un espace euclidien (un espace vectoriel de dimension finie muni d'un produit scalaire) en une base orthonormale (une base où tous les vecteurs sont deux à deux orthogonaux et ont une norme de 1).

Pour concrétiser le procédé de Gram-Schmidt, nous commençons par illustrer deux concepts fondamentaux :


- Projection d'un vecteur sur un autre vecteur
- Projection d'un vecteur sur un sous-espace vectoriel

Ces notions sont essentielles car elles constituent la base du processus d'orthonormalisation.

# Décomposition QR

Procédé d'orthonormalisation de Gram-Schmidt

## Projection d'un vecteur sur un autre





# Décomposition QR

Procédé d'orthonormalisation de Gram-Schmidt




## Projection orthogonale sur un S.E.V

Si  $(u_1, \dots, u_p)$  est une base orthogonale quelconque d'un sous-espace vectoriel  $W$  de  $\mathbb{R}^n$ , alors pour tout vecteur  $y \in \mathbb{R}^n$

$$\text{proj}_W y = \text{proj}_{u_1} y + \dots + \text{proj}_{u_p} y$$

$$\begin{aligned} z &= y - \text{proj}_{u_1} y - \text{proj}_{u_2} y \\ &= y - \frac{\langle y, u_1 \rangle}{\langle u_1, u_1 \rangle} u_1 - \frac{\langle y, u_2 \rangle}{\langle u_2, u_2 \rangle} u_2 \end{aligned}$$

## Projection orthogonale sur un sous-espace vectoriel



# Décomposition QR

## Procédé d'orthonormalisation de Gram-Schmidt

### Procédé de Gram-Schmidt

Pour créer une famille de vecteurs orthonormale  $(e_1, e_2, \dots, e_n)$  à partir d'une famille de vecteurs  $(a_1, a_2, \dots, a_n)$  le procédé d'orthonormalisation de Gram-Schmidt est décrit comme suit:

$$\begin{aligned}
 \mathbf{u}_1 &= \mathbf{a}_1, & \mathbf{q}_1 &= \frac{\mathbf{u}_1}{\|\mathbf{u}_1\|} \\
 \mathbf{u}_2 &= \mathbf{a}_2 - \text{proj}_{\mathbf{u}_1}(\mathbf{a}_2), & \mathbf{q}_2 &= \frac{\mathbf{u}_2}{\|\mathbf{u}_2\|} \\
 \mathbf{u}_3 &= \mathbf{a}_3 - \text{proj}_{\mathbf{u}_1}(\mathbf{a}_3) - \text{proj}_{\mathbf{u}_2}(\mathbf{a}_3), & \mathbf{q}_3 &= \frac{\mathbf{u}_3}{\|\mathbf{u}_3\|} \\
 \mathbf{u}_4 &= \mathbf{a}_4 - \text{proj}_{\mathbf{u}_1}(\mathbf{a}_4) - \text{proj}_{\mathbf{u}_2}(\mathbf{a}_4) - \text{proj}_{\mathbf{u}_3}(\mathbf{a}_4), & \mathbf{q}_4 &= \frac{\mathbf{u}_4}{\|\mathbf{u}_4\|} \\
 &\vdots & &\vdots \\
 \mathbf{u}_k &= \mathbf{a}_k - \sum_{j=1}^{k-1} \text{proj}_{\mathbf{u}_j}(\mathbf{a}_k), & \mathbf{q}_k &= \frac{\mathbf{u}_k}{\|\mathbf{u}_k\|}.
 \end{aligned}$$

où la projection orthogonale est donnée par :

$$\text{proj}_{\mathbf{u}_j}(\mathbf{a}_k) = \frac{\langle \mathbf{a}_k, \mathbf{u}_j \rangle}{\langle \mathbf{u}_j, \mathbf{u}_j \rangle} \mathbf{u}_j$$

# Décomposition QR

Calcul de la matrice triangulaire supérieur  $R$

Après l'obtention de la matrice **orthogonale**  $Q$  par le biais du procédé de **Gram-Schmidt**, le calcul de la matrice **triangulaire supérieure**  $R$  devient immédiat. En effet, cette matrice est obtenue par la relation fondamentale:

$$R = Q^T A$$

où :  $A = [\mathbf{a}_1, \mathbf{a}_2, \dots, \mathbf{a}_n]$  est la **matrice initiale**, et  $Q = [\mathbf{q}_1, \mathbf{q}_2, \dots, \mathbf{q}_n]$  est la **matrice orthogonale** associée.

Ainsi, chaque coefficient de  $R$  est donné par un **produit scalaire** entre les colonnes de  $Q$  et celles de  $A$ , ce qui nous permet d'écrire  $R$  sous la forme explicite :

$$R = \begin{bmatrix} \langle \mathbf{q}_1, \mathbf{a}_1 \rangle & \langle \mathbf{q}_1, \mathbf{a}_2 \rangle & \cdots & \langle \mathbf{q}_1, \mathbf{a}_n \rangle \\ 0 & \langle \mathbf{q}_2, \mathbf{a}_2 \rangle & \cdots & \langle \mathbf{q}_2, \mathbf{a}_n \rangle \\ 0 & 0 & \ddots & \vdots \\ 0 & 0 & 0 & \langle \mathbf{q}_n, \mathbf{a}_n \rangle \end{bmatrix}$$

# Décomposition QR

En conclusion la décomposition  $QR$  d'une matrice est de la forme

$$\begin{bmatrix} | & | & & | \\ a_1 & a_2 & \dots & a_n \\ | & | & & | \end{bmatrix} = \underbrace{\begin{bmatrix} | & | & & | \\ q_1 & q_2 & \dots & q_n \\ | & | & & | \end{bmatrix}}_{\substack{\text{Vecteurs colonnes} \\ \text{orthonormaux obtenue} \\ \text{par Gram Schmidt}}} \cdot \underbrace{\begin{bmatrix} \langle q_1, a_1 \rangle & \langle q_1, a_2 \rangle & \dots & \langle q_1, a_n \rangle \\ 0 & \langle q_2, a_2 \rangle & \dots & \langle q_2, a_n \rangle \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \langle q_n, a_n \rangle \end{bmatrix}}_{\text{Triangulaire supérieure}}$$

# Décomposition QR

## Exemple

Calculons une factorisation  $QR$

$$A = \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 0 & 2 \end{pmatrix}$$

On note,  $A = [\mathbf{a}_1 \mathbf{a}_2]$ , le procédé de Gram-Schmidt donne

$$\mathbf{v}_1 := \mathbf{a}_1 = \begin{pmatrix} 1 \\ 1 \\ 0 \end{pmatrix}, \quad \mathbf{v}_2 := \mathbf{a}_2 - \frac{\mathbf{a}_2 \cdot \mathbf{a}_1}{\|\mathbf{a}_1\|^2} \mathbf{a}_1 = \begin{pmatrix} -1/2 \\ 1/2 \\ 2 \end{pmatrix}$$

La normalisation de  $\mathbf{v}_1$  et  $\mathbf{v}_2$  se traduit comme suit

$$\mathbf{q}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|} = \begin{pmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \\ 0 \end{pmatrix} \quad \mathbf{q}_2 = \frac{\mathbf{v}_2}{\|\mathbf{v}_2\|} = \begin{pmatrix} -\sqrt{2}/6 \\ \sqrt{2}/6 \\ 2\sqrt{2}/3 \end{pmatrix}$$

# Décomposition QR

## Exemple(suite)

On a donc, après normalisation,


$$Q = \begin{pmatrix} \sqrt{2}/2 & -\sqrt{2}/6 \\ \sqrt{2}/2 & \sqrt{2}/6 \\ 0 & 2\sqrt{2}/3 \end{pmatrix}$$

Ensuite,

$$\begin{aligned} R = Q^T A &= \begin{pmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ -\sqrt{2}/6 & \sqrt{2}/6 & 2\sqrt{2}/3 \end{pmatrix} \begin{pmatrix} 1 & 1 \\ 1 & 2 \\ 0 & 2 \end{pmatrix} \\ &= \begin{pmatrix} \sqrt{2} & 3\sqrt{2}/2 \\ 0 & 3\sqrt{2}/2 \end{pmatrix} \end{aligned}$$

# Décomposition en valeurs singulières (SVD)

La décomposition en valeurs singulières (SVD=Singular Value Decomposition) est une méthode très générale de factorisation qui donne une nouvelle interprétation géométrique de n'importe quelle application linéaire  $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$ . Elle consiste à factoriser une matrice quelconque  $A(m \times n)$  en un produit,



# Décomposition en valeurs singulières (SVD)

## Théorème(Existence d'une SVD)

Toute matrice  $A(m \times n)$  peut s'écrire comme un produit,

$$A = U\Sigma V^T$$

où

- $U$  est  $m \times m$ , **orthogonale**:  $U^T U = U U^T = I_m$ ; ses colonnes sont appelées **left singular vectors** de  $A$ .
- $\Sigma$  est  $m \times n$ , **diagonale**, les coefficients situés sur sa diagonale sont  $\geq 0$ , et sont appelés **les valeurs singulières** de  $A$ .
- $V$  est  $n \times n$ , **orthogonale** :  $V^T V = V V^T = I_n$ , ses colonnes sont appelées **right singular vectors** de  $A$ .



# Décomposition en valeurs singulières (SVD)

## Structure de la décomposition SVD

Avant de passer à la structure de toute décomposition SVD, commençons par énoncer les résultats suivants

### Lemme

Pour une matrice  $A(m \times n)$  quelconque,


- $A^T A(n \times n)$  est symétrique,
- $AA^T(m \times m)$  est symétrique,
- Un scalaire  $\lambda \neq 0$  est valeur propre de  $A^T A$  si et seulement si il est également valeur propre de  $AA^T$ ,
- Si  $\lambda$  est valeur propre de  $A^T A$  ou de  $AA^T$ , alors  $\lambda \geq 0$ .

# Décomposition en valeurs singulières (SVD)

## Structure

Les matrices  $U$ ,  $\Sigma$  et  $V^T$  formant une décomposition SVD d'une matrice  $A(m \times n)$  sont constituées comme suit

- $U$ : de taille  $m \times m$  formée des vecteurs propres normalisés de  $AA^T$
- $\Sigma$ : de taille  $m \times n$ , matrice diagonale rectangulaire avec  $r$  racines carrées non nulles de  $A^T A$  ou  $AA^T$ , où  $r$  est le  $\text{rang}(A)$
- $V^T$ : de taille  $n \times n$  formée des vecteurs propres normalisés de  $A^T A$



# Décomposition en valeurs singulières (SVD)

## Structure

- Si  $m < n$

$$\begin{array}{c}
 \boxed{\mathbf{A}} \quad = \quad \boxed{\mathbf{U}} \quad \boxed{\Sigma} \quad \boxed{\mathbf{V}^T} \\
 m \times n \quad m \times m \quad m \times n \quad n \times n
 \end{array}$$

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & \cdots & \cdots & \cdots & 0 \\ 0 & \sigma_2 & \cdots & \cdots & \cdots & 0 \\ 0 & \cdots & \cdots & \cdots & \cdots & 0 \\ 0 & \cdots & \cdots & \sigma_m & \cdots & 0 \end{bmatrix}_{m \times n} \quad \sigma_i = \sqrt{\text{V.p.}(AA^T)}$$

$i = 1 \dots m$

# Décomposition en valeurs singulières (SVD)

## Structure

- Si  $m > n$

$$\begin{array}{c}
 \boxed{\mathbf{A}} \quad = \quad \boxed{\mathbf{U}} \quad \boxed{\Sigma} \quad \boxed{\mathbf{V}^T} \\
 m \times n \quad \quad m \times m \quad m \times n \quad n \times n
 \end{array}$$

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & \cdots & 0 \\ 0 & \sigma_2 & \cdots & 0 \\ 0 & \cdots & \cdots & 0 \\ 0 & \cdots & \cdots & \sigma_n \\ 0 & 0 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & 0 \end{bmatrix}_{m \times n} \quad ; \quad \sigma_i = \sqrt{\text{V.p. de } A^T A}, i = 1 \dots n$$

# Décomposition en valeurs singulières (SVD)

## Exemple

On se propose de décomposer en valeurs singulières  $U\Sigma V^T$  la matrice

$$A = \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

Pour construire la matrice  $V$  on calcule :

$$A^T A = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 1 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$$

dont les valeurs propres sont les racines du polynôme caractéristique

$$\det(A^T A - \lambda I) = \begin{vmatrix} 2 - \lambda & 1 \\ 1 & 2 - \lambda \end{vmatrix} = (2 - \lambda)^2 - 1 = \lambda^2 - 4\lambda + 3$$

$$\Rightarrow \lambda_1 = 3, \quad \lambda_2 = 1$$

# Décomposition en valeurs singulières (SVD)

## Exemple

### Valeurs singulières de $A$ :

$$\sigma_1 = \sqrt{\lambda_1} = \sqrt{3}, \quad \text{et} \quad \sigma_2 = \sqrt{\lambda_2} = \sqrt{1} = 1.$$

Donc la matrice diagonale :

$$\Sigma = \begin{pmatrix} \sqrt{3} & 0 \\ 0 & 1 \\ 0 & 0 \end{pmatrix} \in \mathbb{R}^{3 \times 2}$$

On complète avec une ligne de zéros pour que  $\Sigma$  soit de même taille que  $A$ .

# Décomposition en valeurs singulières (SVD)

## Exemple(suite)

Continuons dans la construction de la matrice  $V$ .

### Vecteurs propres de $A^T A$

La résolution de  $AX = \lambda X$ , pour  $X \neq 0$  donne :

- Valeur propre  $\lambda = 3$  : vecteur propre  $\begin{pmatrix} 1 \\ 1 \end{pmatrix}$
- Valeur propre  $\lambda = 1$  : vecteur propre  $\begin{pmatrix} 1 \\ -1 \end{pmatrix}$

En normalisant (en divisant chaque vecteur par sa norme), on obtient les vecteurs de  $V$

$$v_1 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix}, \quad v_2 = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix} \Rightarrow V = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \end{pmatrix}$$

# Décomposition en valeurs singulières (SVD)

## Exemple(suite)

**Construction des vecteurs de la matrice  $U$ :** Ils existent deux méthodes à suivre.

- 1<sup>ère</sup> méthode :  $U$  est formée des vecteurs propres normalisés de  $AA^T$ , donc il suffit de les calculer d'une manière classique.
- 2<sup>ème</sup> méthode : on a  $A = U\Sigma V^T \Rightarrow U = AV\Sigma^{-1}$ . D'où l'on peut extraire

$$u_i = \frac{1}{\sigma_i} Av_i, \quad i = 1, 2$$

Pour  $u_1$  :

$$Av_1 = A \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix} \Rightarrow u_1 = \frac{Av_1}{\sigma_1} = \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}$$



# Décomposition en valeurs singulières (SVD)

## Exemple(suite)

Même chose pour  $u_2$  avec  $v_2$  :

$$Av_2 = A \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ -1 \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix} \Rightarrow u_2 = \frac{1}{1} \cdot \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}$$

Par ailleurs,  $U$  est constitué de :

$$U = \left[ \frac{1}{\sqrt{6}} \begin{pmatrix} 1 \\ 2 \\ 1 \end{pmatrix}, \quad \frac{1}{\sqrt{2}} \begin{pmatrix} 1 \\ 0 \\ -1 \end{pmatrix}, \quad u_3 \right]$$

Sachant que  $(u_1, u_2, u_3)$  doivent former une base orthonormale, on peut construire  $U_3$  par le procédé d'orthonormalisation de Gram-Schmidt

1. On Choisit un vecteur candidat  $w$  dans  $\mathbb{R}^3$  (au hasard, mais pas colinéaire à  $u_1$  ni  $u_2$  ). Par exemple :

## Exemple(suite)

1. On Choisis un vecteur candidat  $w$  dans  $\mathbb{R}^3$  (au hasard, mais pas colinéaire à  $u_1$  ni  $u_2$  ). Par exemple :

$$w = \begin{pmatrix} 1 \\ 1 \\ 1 \end{pmatrix}$$

2. Enlève les projections sur  $u_1$  et  $u_2$  :

$$u_3 = w - \text{proj}_{u_1}(w) - \text{proj}_{u_2}(w)$$

Où :

$$\text{proj}_{u_i}(w) = \left( \frac{\langle w, u_i \rangle}{\|u_i\|^2} \right) u_i$$

# Décomposition en valeurs singulières (SVD)

## Exemple(suite)

Mais comme  $u_1$  et  $u_2$  sont déjà normalisés, les  $\|u_i\|^2 = 1$ , donc : Mais comme  $u_1$  et  $u_2$  sont déjà normalisés, les  $\|u_i\|^2 = 1$ , donc:

$$u_3 = w - (w \cdot u_1) u_1 - (w \cdot u_2) u_2$$


3. Puis on normalise  $u_3$  :

$$u_3 := \frac{u_3}{\|u_3\|}$$

# Décomposition en valeurs singulières (SVD): illustration

Les matrices **orthogonales** représentent des isométries, c'est-à-dire des transformations rigides de l'espace, et doivent être comprises essentiellement comme **des rotations**. D'autre part, **une matrice diagonale  $m \times n$**  a pour effet de **stretch** certaines directions (avec un changement de dimension, voir plus bas). Donc la décomposition en valeurs singulières permet de décomposer l'application  $T : \mathbb{R}^n \rightarrow \mathbb{R}^m$  définie par  $T(\mathbf{x}) = A\mathbf{x}$  en trois parties :

$$\mathbb{R}^n \xrightarrow{(V^T: \text{rotation})} \mathbb{R}^n \xrightarrow{(\Sigma: \text{stretch})} \mathbb{R}^m \xrightarrow{(U: \text{rotation})} \mathbb{R}^m$$



# Comparaison : Application en Informatique

Que ce soit pour l'optimisation des modèles d'apprentissage automatique, la **compression d'images**, la **détection d'anomalies en cybersécurité**, ou encore la **cryptographie**, chaque méthode présente des avantages spécifiques, renforçant ainsi leur importance dans la résolution de problèmes complexes et l'amélioration des performances des algorithmes.

Décomposition	Machine Learning	Traitement d'Image	Cybersécurité	Cryptographie
QR	Bonne stabilité, rapide pour résoudre $AX = B$	Compression rapide mais moins performante que SVD	Détection rapide d'anomalies	Peut être utilisé pour l'analyse matricielle des clés et la <b>réduction de dimension</b> dans le chiffrement <b>homomorphe</b>
LU	Rapide pour les matrices carrées	Pas idéal pour compression	Moins précis pour anomalies	Peu utilisé directement, mais peut <b>accélérer les calculs</b> dans certains algorithmes cryptographiques
SVD	Très précis mais coûteux	Meilleure compression	Détection fine des anomalies	Utilisé dans la <b>stéganographie</b> , le cryptage par masquage matriciel et l'analyse des systèmes de chiffrement quantique

## ● Applications de la décomposition matricielle avec Python